Fundamentos de la Computación Paralela

Comparación con la Computación Secuencial y Herramientas Clave

27 de mayo de 2025

¿Qué es la Computación Paralela?

- La **computación paralela** es un tipo de computación en el que se ejecutan muchas **cálculos o procesos simultáneamente**.
- El objetivo es resolver problemas grandes que se pueden dividir en partes más pequeñas, las cuales se resuelven *al mismo tiempo*.
- No es exactamente los mismo que la computación de alto rendimiento (HPC).
- Ha ganado interés debido a las restricciones físicas que limitan el aumento de la frecuencia del procesador (frequency scaling) y la preocupación por el consumo de energía y calor.

Secuencial vs. Paralela

Computación Secuencial:

- Los programas se escriben para ejecutarse como un flujo en serial de instrucciones.
- Solo se ejecuta una instrucción a la vez en una sola CPU.

Computación Paralela:

- Utiliza múltiples elementos de procesamiento simultáneamente para resolver un problema.
- Esto se logra dividiendo el problema en partes independientes.
- El aumento del rendimiento ahora proviene de incrementar el número de procesadores (nucleos o nodos) en lugar de hacer que un solo core sea más rápido.

Arquitecturas Paralelas

- Principios de **arquitecturas paralelas y distribuidas**.
- Se pueden clasificar según el nivel de soporte hardware al paralelismo:
 - Computadoras con múltiples elementos de procesamiento en una sola máquina:
 - Multi-core: Múltiples unidades de procesamiento (cores) en el mismo chip. Cada core es independiente.
 - Symmetric Multiprocessing (SMP): Múltiples procesadores idénticos que comparten memoria y se conectan vía bus.
 - Sistemas que usan múltiples computadoras:
 - Clusters: Grupo de computadoras acopladas laxamente que trabajan juntas.
 - Massively Parallel Processors (MPP): Computadoras con muchos procesadores interconectados con redes especializadas.
 - Grid computing: Utiliza computadoras a través de Internet.

Desafíos de la Programación Paralela

- Los algoritmos explícitamente paralelos son más difíciles de escribir que los secuenciales.
- La concurrencia introduce nuevas clases de errores de software, siendo las race conditions las más comunes.
- Es necesaria la sincronización para acceder a recursos compartidos.
- Posibles problemas como deadlock al usar locks.
- La comunicación y sincronización entre subtareas son grandes obstáculos para el rendimiento óptimo.
- Las dependencias de datos (flujo, anti, salida) restringen la paralelización.
- Parallel slowdown: Aumento del tiempo de ejecución por el overhead de comunicación/espera al aumentar la paralelización.

Modelos de Memoria y Comunicación

Memoria Compartida (Shared Memory):

- Todos los elementos de procesamiento comparten un espacio de direcciones único.
- Acceso a memoria con latencia y ancho de banda uniformes (UMA) o no uniformes (NUMA).
- La escalabilidad está limitada en comparación con sistemas de memoria distribuida.

Memoria Distribuida (Distributed Memory):

- Cada elemento de procesamiento tiene su propio espacio de direcciones local.
- La comunicación entre procesos se realiza mediante paso de mensajes.
- Sistemas altamente escalables.
- Ejemplos: Clusters, MPPs.

Leyes de Rendimiento Paralelo

Ley de Amdahl:

- Establece un límite superior teórico a la mejora de velocidad (speedup) de un programa debido a la paralelización.
- El speedup está limitado por la fracción de tiempo que la paralelización puede ser utilizada (la parte secuencial del programa).
- Muestra que el aumento del número de procesadores genera rendimientos decrecientes.
- La mejora óptima se logra balanceando las partes paralelizables y no paralelizables. Tiene limitaciones.

Ley de Gustafson:

 Ofrece una evaluación más realista del rendimiento paralelo al considerar que el tamaño del problema puede escalar con el número de procesadores.

Herramientas Clave (Libraries y APIs)

 Se han creado lenguajes, librerías, APIs y modelos de programación para computadoras paralelas.

OpenMP:

- Librería para programación paralela en sistemas de memoria compartida.
- Proporciona directivas y funciones para crear regiones paralelas, gestionar threads y sincronización.
- MPI (Message Passing Interface):
 - Librería para programación paralela en sistemas de memoria distribuida.
 - Permite la comunicación explícita (paso de mensajes) entre procesos.
 - Es la API de paso de mensajes más utilizada.
- Otras librerías para procesamiento numérico a gran escala: BLAS, LAPACK, ScaLAPACK, ARPACK.

Aplicaciones Típicas de la Computación Paralela

- Históricamente, computación científica y simulación (ej: meteorología).
- Ahora se utiliza en campos variados como omics y economía.
- Tipos comunes de problemas adecuados para paralelizar:
 - Álgebra Lineal Densa y no-Densa.
 - Métodos Espectrales (como Fast Fourier Transform).
 - Problemas de N-cuerpos.
 - Problemas de Malla Estructurada y No Estructurada (ej: análisis de elementos finitos).
 - Método de Monte Carlo.
 - Lógica Combinacional (ej: criptografía de fuerza bruta).
 - Recorrido de Grafos (ej: algoritmos de ordenación).
 - Programación Dinámica.

Conclusión

- La computación paralela es fundamental para lograr aumentos de rendimiento en la era post-frequency scaling.
- Implica un cambio de paradigma de programación, requiriendo manejar la *concurrencia*, *comunicación* y *sincronización*.
- Las arquitecturas varían desde multi-core en desktops hasta clusters y MPPs en supercomputadoras.
- Herramientas como OpenMP (memoria compartida) y MPI (memoria distribuida) son esenciales para desarrollar programas paralelos.
- Permite abordar y resolver problemas complejos y de gran escala que antes eran intratables.
- La investigación en **paralelización automática** continúa, pero la programación explícita es el enfoque dominante.