

Regresión Lineal

4 de junio de 2025

Descenso de Gradiente: Conceptos Fundamentales

- ▶ El **Descenso de Gradiente** es un método para la **optimización matemática sin restricciones**.
- ▶ Es un **algoritmo iterativo de primer orden** diseñado para **minimizar una función multivariante diferenciable**.
- ▶ La idea central es dar **pasos repetidos en la dirección opuesta al gradiente** (o gradiente aproximado) de la función en el punto actual, ya que esta es la dirección de **mayor descenso**.
- ▶ Es particularmente útil en **aprendizaje automático** para la **minimización de la función de costo o pérdida**.
- ▶ Históricamente, se atribuye a Augustin-Louis Cauchy, quien lo sugirió por primera vez en 1847.

Descenso de Gradiente: El Proceso Iterativo

- ▶ El proceso comienza con una estimación inicial \mathbf{x}_0 para un mínimo local de la función F .
- ▶ La secuencia de puntos se define mediante la siguiente regla de actualización:

$$\mathbf{x}_{n+1} = \mathbf{x}_n - \gamma_n \nabla F(\mathbf{x}_n), \quad n \geq 0.$$

- ▶ Aquí, γ_n representa el **tamaño del paso** o la **tasa de aprendizaje** (learning rate). Este valor puede variar en cada iteración.
- ▶ El término $\gamma \nabla F(\mathbf{a})$ se resta de \mathbf{a} porque el objetivo es **moverse en contra del gradiente**, hacia el mínimo local.
- ▶ Este método garantiza una secuencia **monótona no creciente** de valores de la función:
 $F(\mathbf{x}_0) \geq F(\mathbf{x}_1) \geq F(\mathbf{x}_2) \geq \dots$
- ▶ Para funciones convexas, el descenso de gradiente puede converger a la **solución global**, ya que todos los mínimos locales son también mínimos globales.

Aplicación a la Regresión Lineal

- ▶ La **Regresión Lineal** es un modelo estadístico que estima la relación entre una variable de respuesta (dependiente) y una o más variables explicativas (independientes).
- ▶ En este modelo, las relaciones se representan mediante **funciones lineales de predicción**, cuyos parámetros desconocidos se estiman a partir de los datos.
- ▶ El modelo de regresión lineal se expresa como $y_i = \beta_0 + \beta_1 x_{i1} + \dots + \beta_p x_{ip} + \varepsilon_i$ o en forma matricial $\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon}$.
- ▶ Para ajustar un modelo lineal, se estiman los coeficientes de regresión $\boldsymbol{\beta}$ de manera que el **término de error** $\boldsymbol{\varepsilon} = \mathbf{y} - \mathbf{X}\boldsymbol{\beta}$ se minimice.
- ▶ Comúnmente, la medida a minimizar es la **suma de los errores al cuadrado** (MSE): $\|\boldsymbol{\varepsilon}\|_2^2$. Esta es la **función de costo** para el descenso de gradiente.
- ▶ El vector óptimo de parámetros $\vec{\hat{\boldsymbol{\beta}}}$ es aquel que **minimiza esta suma de cuadrados**.

- ▶ En el caso de 2 dimensiones, escribimos:

$$y_i = mx_i + b$$

- ▶ El gradiente de esta función de pérdida L es:

$$\frac{\partial L(D, \vec{\beta})}{\partial \vec{\beta}} = -2X^T Y + 2X^T X \vec{\beta}.$$

- ▶ Al igualar el gradiente a cero, se obtiene la solución de **mínimos cuadrados** : $\hat{\vec{\beta}} = (X^T X)^{-1} X^T Y$.
- ▶ El descenso de gradiente **itera para encontrar este mínimo** actualizando $\vec{\beta}$ en la dirección opuesta al gradiente de la función de pérdida. Para distribuciones de error normales, los resultados de mínimos cuadrados y máxima verosimilitud son idénticos.

Transformación Box-Muller: Generación de Números Aleatorios Normales

- ▶ La **Transformación Box-Muller**, formulada por George Edward Pelham Box y Mervin Edgar Muller, es un **método de muestreo de números aleatorios**.
- ▶ Su propósito es generar **pares de números aleatorios independientes y distribuidos normalmente estándar** (con expectativa cero y varianza unitaria).
- ▶ Para funcionar, requiere una **fuentes de números aleatorios distribuidos uniformemente**.
- ▶ La necesidad de esta transformación surgió como una **alternativa computacionalmente más eficiente** al método de muestreo por transformada inversa.

Transformación Box-Muller: Forma Básica

- ▶ Esta es la forma original dada por Box y Muller.
- ▶ Dadas dos muestras independientes, U_1 y U_2 , de una **distribución uniforme en el intervalo (0,1)**.
- ▶ Luego, las mapea a dos muestras normalmente distribuidas (Z_0 y Z_1) utilizando las siguientes ecuaciones:
 - ▶ $Z_0 = \sqrt{-2 \ln U_1} \cos(2\pi U_2)$
 - ▶ $Z_1 = \sqrt{-2 \ln U_1} \sin(2\pi U_2)$
- ▶ Las variables resultantes Z_0 y Z_1 son **independientes y tienen una distribución normal estándar**.
- ▶ La derivación se basa en la propiedad de un sistema cartesiano bidimensional donde las coordenadas X e Y son variables normales independientes.

Transformación Box-Muller: Forma Polar

- ▶ Esta forma fue propuesta inicialmente por J. Bell y modificada por R. Knop.
- ▶ Toma dos valores, u y v , **independientes y distribuidos uniformemente en el intervalo cerrado** $[-1, +1]$.
- ▶ Se calcula $s = u^2 + v^2$. Si $s = 0$ o $s \geq 1$, se descartan u y v , y se elige otro par.
- ▶ La principal ventaja es que **evita el uso directo de las funciones seno y coseno**, reemplazándolas por divisiones. Esto puede ser beneficioso cuando las funciones trigonométricas son costosas de calcular.
- ▶ Las dos desviaciones normales estándar se producen de la siguiente manera:
 - ▶ $z_0 = u \cdot \sqrt{\frac{-2 \ln s}{s}}$
 - ▶ $z_1 = v \cdot \sqrt{\frac{-2 \ln s}{s}}$
- ▶ La forma polar es un tipo de **muestreo por rechazo**. Descarta aproximadamente el $1 - \pi/4 \approx 21,46\%$ de los pares de números uniformes de entrada.

Transformación Box-Muller: Comparación y Generalización

- ▶ La **forma polar puede ser más rápida** que la forma básica en algunos casos, ya que las divisiones pueden ser computacionalmente menos costosas que las funciones trigonométricas, a pesar de que desecha algunos números generados.
- ▶ La forma básica requiere dos multiplicaciones, $1/2$ logaritmo, $1/2$ raíz cuadrada y una función trigonométrica por cada variable normal generada.
- ▶ La forma polar requiere $3/2$ multiplicaciones, $1/2$ logaritmo, $1/2$ raíz cuadrada y $1/2$ división por cada variable normal generada, reemplazando una multiplicación y una función trigonométrica con una división y un bucle condicional.
- ▶ **Generalización a cualquier distribución normal:**
 - ▶ La transformación Box-Muller estándar genera valores de una **distribución normal estándar** ($\mu = 0$, $\sigma = 1$).
 - ▶ Para obtener valores de cualquier distribución normal con **media μ y varianza σ^2** , se puede aplicar la fórmula: $X = Z\sigma + \mu$, donde Z es un valor normal estándar generado por Box-Muller.

¡Gracias por su atención!